# CASO PRÁCTICO 4

**Se pide**

Crear una aplicación de PySpark que se pueda ejecutar con Spark Streaming y que cumpla los siguientes requisitos:

- Utilizar como origen de datos un socketTextStream en el puerto 9998.
- Debe actualizarse cada 10 segundos.
- En cada microbatch, debe mostrarse por pantalla el resultado por cada DStream de todos aquellos que en cada frase contengan la palabra Streaming.
- Deben almacenarse en Hadoop los resultados en los que aparezca la cadena de texto Streaming, en un directorio llamado “practica_final/TuNombre”. Quedarán directorios en HDFS como, por ejemplo:

`/user/bigdata/practica_final/JuanManuel-1647894600000`

**Solución:**

Antes que nada, para evitar futuros problemas indicaremos las rutas de configuración de **Hadoop** y **YARN**. Para ello, definimos las variables de entorno y además hacemos que **Spark** herede el classpath de Hadoop.

```
bigdata@bigdata-IMF:~$ export HADOOP_HOME=/home/bigdata/hadoop
bigdata@bigdata-IMF:~$ export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
bigdata@bigdata-IMF:~$ export YARN_CONF_DIR=$HADOOP_HOME/etc/hadoop
bigdata@bigdata-IMF:~$ export SPARK_HOME=/home/bigdata/spark
bigdata@bigdata-IMF:~$ export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin:$SPARK_HOME/bin
bigdata@bigdata-IMF:~$ export SPARK_DIST_CLASSPATH="$($HADOOP_HOME/bin/hadoop classpath)"
bigdata@bigdata-IMF:~$
```

Una vez configurado todo, iniciamos **HDFS** y **YARN**, y verificamos que los procesos necesarios se están ejecutando.

```
bigdata@bigdata-IMF:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [bigdata-IMF]
bigdata@bigdata-IMF:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
bigdata@bigdata-IMF:~$ jps
47298 DataNode
49059 Jps
47525 SecondaryNameNode
48778 NodeManager
47146 NameNode
48299 ResourceManager
bigdata@bigdata-IMF:~$
```

1. Carpeta de resultados en **HDFS**:

    a. Creamos la carpeta donde se guardarán los resultados en **HDFS** y verificamos su existencia en el directorio.

```
bigdata@bigdata-IMF:~$ hdfs dfs -mkdir -p /user/bigdata/practica_final
bigdata@bigdata-IMF:~$ hdfs dfs -ls /user/bigdata
Found 1 items
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:49 /user/bigdata/practica_final
bigdata@bigdata-IMF:~$
```

2. Carpeta local del proyecto y script:

    a. Creamos la carpeta local del proyecto y nos dirigimos a ella.

```
bigdata@bigdata-IMF:~$ cd ~
bigdata@bigdata-IMF:~$ mkdir -p practica_streaming
bigdata@bigdata-IMF:~$ cd practica_streaming
bigdata@bigdata-IMF:~/practica_streaming$
```

    b. Utilizamos nano para crear el script ***nano streaming_practica.py***

c. A continuación definimos el script:

```
from __future__ import print_function
import sys
from pyspark import SparkConf, SparkContext
from pyspark.streaming import StreamingContext

if __name__ == "__main__":
    if len(sys.argv) != 2:
        print("Uso: streaming_practica.py <GonzaloPrieto>", file=sys.stderr)
        sys.exit(-1)

    tu_nombre = sys.argv[1]

    1) Configuración de Spark
    conf = (SparkConf()
            .setAppName("PracticaFinalStreaming")
           )

    sc = SparkContext(conf=conf)
    sc.setLogLevel("WARN")

    # Intervalo de microbatch: 10 segundos
    ssc = StreamingContext(sc, 10)

    2) Origen de datos: socketTextStream puerto 9998
    host = "localhost"
    port = 9998
    lines = ssc.socketTextStream(host, port)

    3) Filtrar solo líneas que contengan exactamente "Streaming"
    matches = lines.filter(lambda s: "Streaming" in s)

    4) Mostrar resultado por pantalla en cada microbatch
    matches.pprint()

    5) Guardar resultados en HDFS
    HDFS_PREFIX = f"hdfs:///user/bigdata/practica_final/{GonzaloPrieto}"
    matches.repartition(1).saveAsTextFiles(HDFS_PREFIX)

    6) Iniciar el streaming
    ssc.start()
    ssc.awaitTermination()
```

```
  GNU nano 4.8                    streaming_practica.py                    Modificado
from __future__ import print_function
import sys
from pyspark import SparkConf, SparkContext
from pyspark.streaming import StreamingContext

if __name__ == "__main__":
    if len(sys.argv) != 2:
        print("Uso: streaming_practica.py <GonzaloPrieto>", file=sys.stderr)
        sys.exit(-1)

    tu_nombre = sys.argv[1]

    conf = (SparkConf()
            .setAppName("PracticaFinalStreaming")

            )

    sc = SparkContext(conf=conf)
    sc.setLogLevel("WARN")

    ssc = StreamingContext(sc, 10)


    host = "localhost"
    port = 9998
    lines = ssc.socketTextStream(host, port)


    matches = lines.filter(lambda s: "Streaming" in s)


    matches.pprint()


    HDFS_PREFIX = f"hdfs:///user/bigdata/practica_final/{GonzaloPrieto}"
    matches.repartition(1).saveAsTextFiles(HDFS_PREFIX)


    ssc.start()
    ssc.awaitTermination()

^G Ver ayuda   ^O Guardar      ^W Buscar      ^K Cortar Texto ^J Justificar   ^C Posición    M-U Deshacer   M-A Marcar texto M-] A llave     M-Q Anterior   ^B Atrás       ^← Palabr ant
^X Salir       ^R Leer fich.   ^\ Reemplazar  ^U Pegar        ^T Ortografía   ^_ Ir a línea  M-E Rehacer   M-6 Copiar       ^Q Buscar atrás M-W Siguiente  ^F Adelante    ^→ Palabra Siguiente
```

d. Guardamos el script con Ctrl + O y salimos con Ctrl + X.

3. Lanzar la aplicación con **spark-submit** (**YARN**):

a. Lanzamos la aplicación desde la carpeta local del proyecto.

```
bigdata@bigdata-IMF:~/practica_streaming$ spark-submit \
>    --master yarn \
>    --deploy-mode client \
>    --conf spark.streaming.stopGracefullyOnShutdown=true \
>    streaming_practica.py GonzaloPrieto
```

4. Abrir el socket y enviar frases:

a. Paralelamente abrimos otra terminal y nos conectamos al socket:

```
bigdata@bigdata-IMF:~$ nc -lk 9998
```

b. Escribimos las frases que queramos, con o sin la palabra streaming, y al menos en diferentes intervalos de diez segundos.

```
bigdata@bigdata-IMF:~$ nc -lk 9998

Esta frase tiene la palabra Streaming
STREAMING esta no aparecera
Streaming
Esta si, streaming streaming
Streaming
837484739827785278 Streaming
```

c. Volvemos a la terminal de **spark-submit** para observar los distintos microbatch y las frases impresas, las cuales se están guardando en **HDFS**. Podemos observar que las frases con la palabra “Streaming” han sido correctamente impresas.

```
bigdata@bigdata-IMF:~/practica_streaming$ spark-submit \
>   --master yarn \
>   --deploy-mode client \
>   --conf spark.streaming.stopGracefullyOnShutdown=true \
>   streaming_practica.py GonzaloPrieto
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/home/bigdata/spark/jars/slf4j-log4j12-1.7.30.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/home/bigdata/hadoop/share/hadoop/common/lib/slf4j-log4j12-1.7.30.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory]
-------------------------------------------
Time: 2025-11-25 19:57:50
-------------------------------------------
Esta frase tiene la palabra Streaming
Streaming

-------------------------------------------
Time: 2025-11-25 19:58:00
-------------------------------------------

-------------------------------------------
Time: 2025-11-25 19:58:10
-------------------------------------------

-------------------------------------------
Time: 2025-11-25 19:58:20
-------------------------------------------

-------------------------------------------
Time: 2025-11-25 19:58:30
-------------------------------------------

-------------------------------------------
Time: 2025-11-25 19:58:40
-------------------------------------------
Streaming

-------------------------------------------
Time: 2025-11-25 19:58:50
-------------------------------------------
837484739827785278 Streaming
```

5. Comprobar los resultados en **HDFS**:

a. Vemos las carpetas que han sido creadas en el directorio **HDFS**.

```
bigdata@bigdata-IMF:~/practica_streaming$ hdfs dfs -ls /user/bigdata/practica_final
Found 16 items
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:57 /user/bigdata/practica_final/GonzaloPrieto-1764097070000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097080000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097090000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097100000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097110000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097120000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097130000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097140000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097150000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097160000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097170000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097180000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097190000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 20:00 /user/bigdata/practica_final/GonzaloPrieto-1764097200000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 20:00 /user/bigdata/practica_final/GonzaloPrieto-1764097210000
drwxr-xr-x   - bigdata supergroup          0 2025-11-25 20:00 /user/bigdata/practica_final/GonzaloPrieto-1764097220000
bigdata@bigdata-IMF:~/practica_streaming$
```

b. Vemos los microbatch que están guardados dentro. Se pueden apreciar los microbatch con datos, que, a diferencia de los demás, tienen un tamaño mayor que cero.

```
bigdata@bigdata-IMF:~/practica_streaming$ hdfs dfs -ls /user/bigdata/practica_final/GonzaloPrieto-*
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:57 /user/bigdata/practica_final/GonzaloPrieto-1764097070000/_SUCCESS
-rw-r--r--   1 bigdata supergroup         48 2025-11-25 19:57 /user/bigdata/practica_final/GonzaloPrieto-1764097070000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097080000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097080000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097090000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097090000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097100000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097100000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097110000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097110000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097120000/_SUCCESS
-rw-r--r--   1 bigdata supergroup         10 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097120000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097130000/_SUCCESS
-rw-r--r--   1 bigdata supergroup         29 2025-11-25 19:58 /user/bigdata/practica_final/GonzaloPrieto-1764097130000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097140000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097140000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097150000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097150000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097160000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097160000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097170000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097170000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097180000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097180000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097190000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 19:59 /user/bigdata/practica_final/GonzaloPrieto-1764097190000/part-00000
Found 2 items
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 20:00 /user/bigdata/practica_final/GonzaloPrieto-1764097200000/_SUCCESS
-rw-r--r--   1 bigdata supergroup          0 2025-11-25 20:00 /user/bigdata/practica_final/GonzaloPrieto-1764097200000/part-00000
```

c. Por último, verificamos que los resultados se encuentren en el directorio en **HDFS**. Como resultado observamos todas las frases que superaron el filtro impuesto por el script y que han sido guardadas en un archivo de texto.

```
bigdata@bigdata-IMF:~/practica_streaming$ hdfs dfs -cat /user/bigdata/practica_final/GonzaloPrieto-*/part-00000 | sed -n '1,50p'
Esta frase tiene la palabra Streaming
Streaming
Streaming
837484739827785278 Streaming
bigdata@bigdata-IMF:~/practica_streaming$
```